

# Homework 1 Question3

December 12, 2025

## 1 3.3

### (3) Comparação entre Softmax, Sparsemax e Relumax

Consideremos o caso  $K = 2$ , com logits

$$z = [0, t].$$

**Softmax.** A probabilidade da segunda classe é

$$\text{softmax}(z)_2 = \frac{e^t}{e^0 + e^t} = \frac{e^t}{1 + e^t}.$$

A derivada em relação a  $t$  é

$$\frac{d}{dt} \text{softmax}(z)_2 = \frac{(1 + e^t)e^t - e^t e^t}{(1 + e^t)^2} = \frac{e^t}{(1 + e^t)^2}.$$

**Sparsemax.** A sparsemax é definida por

$$\text{sparsemax}(z)_i = [z_i \tau]_+, \quad \text{com } \sum_i [z_i - \tau]_+ = 1.$$

Para  $z = [0, t]$  com  $t > 1$ , obtemos

$$\text{sparsemax}(z) = [0, 1].$$

Logo,

$$\frac{d}{dt} \text{sparsemax}(z)_2 = 1.$$

**Relumax.** Definimos a relumax como

$$\text{relumax}(z)_i = \frac{\text{ReLU}(z_i - \max(z) + b)}{\sum_j \text{ReLU}(z_j - \max(z) + b)}.$$

Para  $z = [0, t]$ , temos  $\max(z) = t$ , logo:

$$\text{relumax}(z)_2 = \frac{\text{ReLU}(b)}{\text{ReLU}(-t+b) + \text{ReLU}(b)}.$$

Se  $b > 0$  e  $-t + b > 0$ , então

$$\text{relumax}(z)_2 = \frac{b}{(-t+b)+b} = \frac{b}{-t+2b}.$$

A derivada em relação a  $t$  é então

$$\frac{\partial}{\partial t} \text{relumax}(z)_2 = \begin{cases} \frac{-b}{(-t+2b)^2}, & -t+b > 0 \\ 0, & -t+b \leq 0 \end{cases}$$

e a derivada em relação a  $b$  é

$$\frac{\partial}{\partial b} \text{relumax}(z)_2 = \begin{cases} \frac{-t}{(-t+2b)^2}, & -t+b > 0 \\ 0, & -t+b \leq 0. \end{cases}$$

### Resumo.

- O softmax é suave e tem derivada sempre positiva.
- A sparsemax é linear por partes e pode ter gradiente constante.
- A relumax introduz uma normalização baseada em ReLU e depende do parâmetro  $b$ .